简明研究路线图

Jared Kaplan

go/roadmap

[先前文档：Research Vision、Ambitious Timeline、April Sketch、May Sketch、RL for Tool Use、Alignment]

最后更新：2021 年 7 月。

长期目标

我们的最高目标是致力于创造安全、有益的 AGI。

作为概念验证，我们正在开发一个通用 AI 助手，它可以与用户对话式交互、创建、编辑和解释软件。这个助手最具雄心的版本可以回答一般性问题、编写函数、识别 bug、设计 API、讨论风格与最佳实践等等——它将具备一位软件工程师同事的全部能力。我们不指望立刻实现这一目标，但这是我们努力的方向。

我们的所有研究项目，都可以视为理解并构建这个 proto-AGI 各个方面的尝试。我们目前认为，这需要具备长时记忆的大型生成式模型，并通过 RL 结合自动化奖励与人类反馈进行微调。

规模化

主要目标：

- 设计能以极高 GPU 利用率和灵活 API 训练超大模型的系统，并能高效采样以用于 RL
- 随着系统效率提升，保持易用性和上手体验——例如，超参数对非专家也很容易设置；我们可以试验高度优化的组件（如 blocksparse attention），即把“黑魔法”封装起来、可与普通组件互换
- 改善我们的安全态势——尤其是针对我们最有价值的资产，如大模型权重
- 降低未来硬件（如 TPU、Trainium 等）的风险，为算力采购做好准备

可解释性

主要目标：

- 围绕大语言模型的基本构件（神经元、注意力头、电路）及其特征统计量来定位我们的认识

- 探索具体能力背后的具体机制，如算术、不同角色间的逼真对话、编程

预训练与数据

主要目标：

- 预训练出最好的语言+代码模型，并开放给 Anthropic 其他团队做进一步微调与定性探索
- 构建尽可能最好的数据集，包括自然语言、代码、diff、PR、debugging 记录及相应的代码评测（如适用）
- 在 Diffs、PR、Wikidiffs、Metadata 等数据上微调原始模型，使模型行为与人类意图相连（其他示例）

研究其科学原理：

- 训练任意大模型（1T 及以上）所需的 ML 进展，同时为其后续使用和进一步微调做好能力优化
- 超大上下文（或能装入大量记忆/经验的等价物）
- 数据质量，包括过滤、迁移、微调与多样性，为更先进模型与 RL 环境的比较奠定基础

人类反馈与对齐

主要目标：

- 用人类反馈训练大语言模型，使其总体上乐于助人：提供帮助、回应反馈、提出并回答澄清性问题
- 识别对齐失败，分类并理解简单与困难挑战
- 对齐的规模定律（Scaling Laws for Alignment）
  - 研究奖励模型的对齐与鲁棒性，既针对 on-policy 人类反馈数据，也针对 stack exchange 等静态数据集及 GAN-判别器训练生成的数据集
  - 建立对“如何最优利用人类反馈”的总体理解：需要到什么程度、实现对齐目标需要哪些资源投入

其他议题与关联：

- 研究 GAN/判别器训练与测试时计算的规模定律，比较数据多样性与在更窄分布上的最终表现
- 研究人类判断与模型对行为判断、样本质量之间的对应关系，模型“自我评判”的能力，以及与偏见、公平性和社会后果的联系

工具使用的 RL

主要目标：

- 加深我们对通向 AGI 路径的理解：探索大型 LM 使用工具、以及学习/生成关于其环境与目标的数据的能力

批注 [1]：（眼睛表情）[作者：Catherine Olsson]，[创建者：1297307460]，[日期：2021/7/16 17:28]

批注 [2]：这类数据源看起来非常有价值；如果大家想到其他来源欢迎补充！[作者：Sam McCandlish]，[创建者：1297307460]，[日期：2021/7/16 17:29]

批注 [3]：stackoverflow、issues、comments 等 [作者：Dario Amodei]，[创建者：1297307460]，[日期：2021/7/16 17:29]

… [1]

批注 [4]：https://www.notion.so/anthropic/Data-Brainstorm-cc8c5496215c4108a44ebd4df5ea5a9e [作者：Jared Kaplan]，[创建者：1297307460]，[日期：2021/7/16 17:30]

… [2]

批注 [5]：非常希望能把这些跟可解释性联系起来。[作者：Christopher Olah]，[创建者：1297307460]，[日期：2021/7/16 17:32]

… [3]

批注 [6]：+1！[作者：Sam McCandlish]，[创建者：1297307460]，[日期：2021/7/16 17:33]

批注 [7]：类似“睡眠”，比如周期性的批量 backprop [作者：Ben Mann]，[创建者：1297307460]，[日期：2021/7/16 17:28]

… [4]

批注 [8]：或者 @colah@anthropic.com 提到的那种软数据库查询的东西 [作者：Sam McCandlish]，[创建者：1297307460]，[日期：2021/7/16 17:30]

… [5]

批注 [9]：skeletonization（@dawn@anthropic.com 做过相关工作）[作者：Sam McCandlish]，[创建者：1297307460]，[日期：2021/7/16 17:36]

… [6]

批注 [10]：我有点担心，如果我们最终在自然语言上做对齐研究、在代码上做能力研究。这两者之间似乎应该始终保持相当紧密的联系

… [7]

批注 [11]：一个可能的原则：“默认情况下，能力研究与对齐研究在各领域应保持比例，除非我们能给出充分理由说明它们应当分开”。这是好原则还是坏原则？

… [8]

批注 [12]：我的大问题：如何安全地部署非沙箱工具？[作者：Sam McCandlish]，[创建者：1297307460]，[日期：2021/7/16 17:31]

… [9]

批注 [13]：具体来说，是在部署时执行代码的工具！[作者：Dario Amodei]，[创建者：1297307460]，[日期：2021/7/16 17:31]

… [10]

高度机密——仅限律师查阅

- 在搜索、printf 调试及其他有价值任务上看到明确的生命迹象；评估工具使用与 RL 是否正在消解当前大模型的局限
- 识别能让“随训练算力扩展”更有利（相比监督学习）的训练技术

社会影响

主要目标：

- 创造全新方式来评估模型对社会影响的潜力（如经济影响、偏见特征、由底层数据决定的生成偏好）；借此提升我们理解日益强大模型的能力
- 帮助第三方（学术界、政府、其他公司）提升衡量和评估 AI 系统的能力；借此提高 AI 生态系统的整体安全性，并建立我们与其他参与者之间的信任
- 扩大能够对模型进行评估和实验的第三方范围，帮助我们更深入地理解模型能力

批注 [14]：仓库浏览（repo browsing）看起来也是一个简单而有价值的入门工具 [作者：Tom Brown]，[创建者：1297307460]，[日期：2021/7/16 17:29]

… [11]

批注 [15]：强烈 +1。我觉得如果给 Copilot 加一项能力，“去查我项目的类型定义”会是很有力的候选。[作者：Nelson Elhage]，[创建者：1297307460]，[日期：2021/7/16 17:30]

… [12]

批注 [16]：特别是对你从未见过、也没载入 IDE 的仓库（比如 matplotlib）[作者：Ben Mann]，[创建者：1297307460]，[日期：2021/7/16 17:30]

… [13]

批注 [17]：是的，基本就是代码编辑器。我还想推荐一下自然语言编辑器——我知道我们更关注代码，但我认为 Google Docs 那种编辑风格里也有有趣的安全性工作和有趣的应用

… [14]

批注 [18]：我觉得这里有点张力：一边是“打造最强辅助程序员”，repo 搜索百分百是最佳起点；另一边是“令人信服地演示工具使用”，printf + 编辑器使用远胜于 repo 搜索。[作者：Andy

… [15]

批注 [19]：我认为计划是短期优先后者、长期优先前者。[作者：Dario Amodei]，[创建者：1297307460]，[日期：2021/7/16 17:38]

… [16]

批注 [20]：在其他某个顶层目标文档里有一段话，大意是：“以身作则，鼓励其他所有人做有伦理的 ML 研究”。Dario 在第一次面试中提到过，我觉得特别有感染力；它一直留在

… [17]

批注 [21]：我个人把它看作全公司层面的事 [作者：Thomas Henighan]，[创建者：1297307460]，[日期：2021/7/16 17:30]

批注 [22]：是的，我把它视为一个通用的顶层目标 [作者：Jared Kaplan]，[创建者：1297307460]，[日期：2021/7/16 17:31]

批注 [23]：这是我快写完的公司愿景文档里的一个顶层目标，可以看作比研究路线图高一层。[作者：Dario Amodei]，[创建者：1297307460]，[日期：2021/7/16

… [18]

批注 [24]：要不要给“第三方”加个限定词，比如“aligned（对齐的）”？我知道基本隐含了，但好奇我们想怎么挑选这些人 [作者：Ben Mann]，[创建者：1297307460]，[日期：2021/7/16 17:

… [19]

第 2 页：[1] 批注 [3] Dario Amodei 2021/7/16 17:29

stackoverflow、issues、comments 等 [作者：Dario Amodei]，[创建者：1297307460]，[日期：2021/7/16 17:29]

第 2 页：[2] 批注 [4] Jared Kaplan 2021/7/16 17:30

https://www.notion.so/anthropic/Data-Brainstorm-cc8c5496215c4108a44ebd4df5ea5a9e [作者：Jared Kaplan]，[创建者：1297307460]，[日期：2021/7/16 17:30]

第 2 页：[3] 批注 [5] Christopher Olah 2021/7/16 17:32

非常希望能把这些跟可解释性联系起来。[作者：Christopher Olah]，[创建者：1297307460]，[日期：2021/7/16 17:32]

第 2 页：[4] 批注 [7] Ben Mann 2021/7/16 17:28

类似“睡眠”，比如周期性的批量 backprop [作者：Ben Mann]，[创建者：1297307460]，[日期：2021/7/16 17:28]

第 2 页：[5] 批注 [8] Sam McCandlish 2021/7/16 17:30

或者 @colah@anthropic.com 提到的那种软数据库查询的东西 [作者：Sam McCandlish]，[创建者：1297307460]，[日期：2021/7/16 17:30]

第 2 页：[6] 批注 [9] Sam McCandlish 2021/7/16 17:36

skeletonization（@dawn@anthropic.com 做过相关工作）[作者：Sam McCandlish]，[创建者：1297307460]，[日期：2021/7/16 17:36]

第 2 页：[7] 批注 [10] Amanda Askell 2021/7/16 17:37

我有点担心，如果我们最终在自然语言上做对齐研究、在代码上做能力研究。这两者之间似乎应该始终保持相当紧密的联系。如果我们在做对齐研究的领域没有提升能力，就会限制我们能测试的对齐程度以及这项工作的用处。这会产生连锁反应，比如对齐研究变成孤岛，因为我们没有及早整合。[作者：Amanda Askell]，[创建者：1297307460]，[日期：2021/7/16 17:37]

第 2 页：[8] 批注 [11] Amanda Askell 2021/7/16 17:40

一个可能的原则：“默认情况下，能力研究与对齐研究在各领域应保持比例，除非我们能给出充分理由说明它们应当分开”。这是好原则还是坏原则？[作者：Amanda Askell]，[创建者：1297307460]，[日期：2021/7/16 17:40]

第 2 页：[9] 批注 [12] Sam McCandlish 2021/7/16 17:31

我的大问题：如何安全地部署非沙箱工具？[作者：Sam McCandlish]，[创建者：1297307460]，[日期：2021/7/16 17:31]

第 2 页：[10] 批注 [13] Dario Amodei 2021/7/16 17:31

具体来说，是在部署时执行代码的工具！[作者：Dario Amodei]，[创建者：1297307460]，[日期：2021/7/16 17:31]

第 3 页：[11] 批注 [14] Tom Brown 2021/7/16 17:29

仓库浏览看起来也是一个简单而有价值的入门工具 [作者：Tom Brown]，[创建者：1297307460]，[日期：2021/7/16 17:29]

第 3 页：[12] 批注 [15] Nelson Elhage 2021/7/16 17:30

强烈 +1。我觉得如果给 Copilot 加一项能力，“去查我项目的类型定义”会是很有力的候选。[作者：Nelson Elhage]，[创建者：1297307460]，[日期：2021/7/16 17:30]

第 3 页：[13] 批注 [16] Ben Mann 2021/7/16 17:30

特别是对你从未见过、也没载入 IDE 的仓库（比如 matplotlib）[作者：Ben Mann]，[创建者：1297307460]，[日期：2021/7/16 17:30]

第 3 页：[14] 批注 [17] Dario Amodei 2021/7/16 17:31

是的，基本就是代码编辑器。我还想推荐一下自然语言编辑器——我知道我们更关注代码，但我认为 Google Docs 那种编辑风格里也有有趣的安全性工作和有趣的应用。支持这些所需的工具和基础设施大多相同。[作者：Dario Amodei]，[创建者：1297307460]，[日期：2021/7/16 17:31]

第 3 页：[15] 批注 [18] Andy Jones 2021/7/16 17:31

我觉得这里有点张力：一边是“打造最强辅助程序员”，repo 搜索百分百是最佳起点；另一边是“令人信服地演示工具使用”，对此 printf + 编辑器使用要重要得多（>>>> repo 搜索）。[作者：Andy Jones]，[创建者：1297307460]，[日期：2021/7/16 17:31]

第 3 页：[16] 批注 [19] Dario Amodei 2021/7/16 17:38

我认为计划是短期优先后者、长期优先前者。[作者：Dario Amodei]，[创建者：1297307460]，[日期：2021/7/16 17:38]

第 3 页：[17] 批注 [20] Andy Jones 2021/7/16 17:30

在其他某个顶层目标文档里有一段话，大意是：“以身作则，鼓励其他所有人做有伦理的 ML 研究”。Dario 在我们第一次面试中提到过，我觉得特别有感染力；它一直留在我脑海里，就像“为 ML 研究建一座山巅之城”。不知道这算不算一个顶层目标，也不知道它应该算“社会影响”还是全公司层面的事。[作者：Andy Jones]，[创建者：1297307460]，[日期：2021/7/16 17:30]

第 3 页：[18] 批注 [23] Dario Amodei 2021/7/16 17:31

这是我快写完的公司愿景文档里的一个顶层目标，可以看作比研究路线图高一层。[作者：Dario Amodei]，[创建者：1297307460]，[日期：2021/7/16 17:31]

第 3 页：[19] 批注 [24] Ben Mann 2021/7/16 17:32

要不要给“第三方”加个限定词，比如“aligned（对齐的）”？我知道基本隐含了，但好奇我们想怎么挑选这些人 [作者：Ben Mann]，[创建者：1297307460]，[日期：2021/7/16 17:32]